

Četvrti domaći zadatak

Ljubica Vujović
Profesor: Predrag Tadić
Statistička klasifikacija signala

Oktobar 2017

1 Metod nosećih vektora

Ovaj metod supervizijskog učenja uvodi koncept funkcionalne i geometrijske margine. Funkcionalna margina predstavlja meru pouzdanosti i tačnosti rešenja. Matematički se definiše na sledeći način:

$$i = y^{(i)}(w^T x^{(i)} + b) \quad (1)$$

Za pozitivne izlazne promenljive, $(w^T x^{(i)})$ će biti pozitivno, pa je i funkcionalna margina pozitivna i obrnuto. Pored funkcionalne, uvodi se pojam i geometrijske margine. Ona predstavlja fizičko rastojanje odbirka od separacione prave. Definiše se na sledeći način:

$$i = y^{(i)}\left(\frac{w^T}{|w|}x^{(i)} + \frac{b}{|w|}\right) \quad (2)$$

Ovaj model se trudi da maksimizuje geometrijsku marginu, što rezultuje u pronalaženju klasifikacione linije tako da prostor izmeu klasa bude što veći.

Pored linearno separabilnih problema, metod nosećih vektora je koristan i kod nelinearno separabilnih zato što uvoenjem kernela, ovaj model uvodi dodatne dimenzije pa problem u tom višedimenzionog prostoru može da postane linearno separabilan.

Na sledećoj slici su prikazani podaci sa klasifikacionom linijom dobijom ovom metodom.




Figure 1: *SVM sa linearnim kernelom*

Preciznost ovog modela je 1.

Uvodjenjem regularizacije, vidimo da dobijamo prirodnu klasifikacionu liniju. Regularizacija je kontrolisana parametrom C . Naime, ako je ovaj parametar mali, to znači će efekat regularizacije biti izraženiji, odnosno iako potencijalno može dati manju preciznost na trening setu, ovakav model ima veću sposobnost generalizacije jer se nije preobučio na već vidjenim podacima. Na sledećim slikama su prikazani rezultati za vrednosti konstante 1 i 10, respektvno a preciznost klasifikacije iznosi 0.98 u oba slučaja.




Figure 2: *SVM sa linearnim kernelom sa konstantom regularizacije $C=1$*

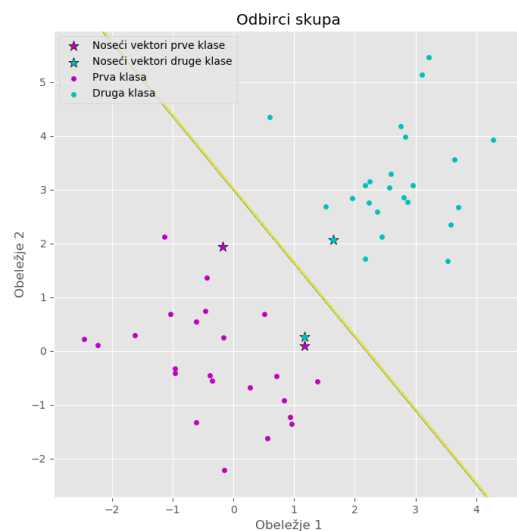


Figure 3: *SVM sa linearnim kernelom sa konstantom regularizacije $C=10$*

U slučaju nelinearno seperabilnih klasa, potrebno je primeniti neki od ker-

nelala. U ovom radu primenjem je polinomijalni kernel. Red polinoma je 5. Uvodjenjem regularizacije dobijamo dosta bolju preciznost. Na sledećim graphicima su prikazane klasifikacione krive za $C=1$ i $C=10$, respektivno. Preznost prvog modela iznosi 0.99, a drugog 0.74. Kernel je odabran zbog prirode seta podataka. Intuitivno vidimo da bi kriva koja razdvaja dve klase trebalo da bude polinom neparnog stepena. Medjutim, isproban je i Gausov kernel i on je imao lošije performanse od polinomijalnog kernela na ovom setu podataka za istu konstantu regularizacije.




Figure 4: *SVM sa polinomijalnim kernelom sa konstantom regularizacije $C=1$*




Figure 5: *SVM sa polinomijalnim kernelom sa konstantom regularizacije $C=10$*